NAMA : Muhammad Nadhif Ihdar

NIM : 240210502042

KELAS : Sistem Cerdas B

ANALISIS PROSES DAN HASIL LATIHAN/STUDI KASUS MODUL 1 DATA MINING

1. Struktur dan Kelengkapan Dataset

Dataset berhasil dibaca dengan ukuran 100 baris x 8 kolom. Hasil df.info() menunjukkan seluruh kolom memiliki Non-Null Count sebesar 100, artinya tidak ditemukan missing value pada dataset ini. Tipe data yang terbaca Pandas sudah sesuai: atribut teks (NIM, Jurusan, Kategori_Kehadiran, Status_Lulus) terbaca sebagai str/object; Jam_Belajar_Minggu sebagai int64; Persentase_Kehadiran, Skor_Ujian_Tengah, dan IPK sebagai float64

2. Statistik Deskriptif Atribut Numerik

	Jam_Belajar_Minggu	Persentase_Kehadiran	Skor_Ujian_Tengah	IPK
count	100.00	100.00	100.00	100.00
mean	26.52	74.85	70.97	3.02
std	11.31	14.85	18.87	0.60
min	5.00	50.72	40.65	2.03
25%	18.00	62.48	56.80	2.45
50%	28.00	75.21	71.91	3.01
75%	36.00	87.53	87.41	3.58
max	44.00	99.53	99.58	4.00

Interpretasi : Rentang nilai (min-max) pada setiap atribut mendekati batas rentang yang ditetapkan saat pembangkitan data, dan nilai kuartil (25%, 50%, 75%) terdistribusi hampir merata di sepanjang rentang tersebut. Hal ini mengindikasikan bahwa data numerik dibangkitkan dari distribusi seragam (uniform), bukan distribusi normal. Standar deviasi yang relatif besar pada seluruh atribut menunjukkan variasi nilai yang tinggi antarobservasi.

3. Frekuensi dan Presentase Atribut Kategorikal

```
=== Atribut: Jurusan ===
```

Jurusan	Frekuensi	Persentase (%)
Teknik Komputer	30	30.0
Sistem Informasi	26	26.0
Data Science	24	24.0
Teknik Informatika	20	20.0

```
=== Atribut: Kategori_Kehadiran ===
```

Kategori_Kehadiran	Frekuensi	Persentase (%)
Tinggi	39	39.0
Rendah	35	35.0
Sedang	26	26.0

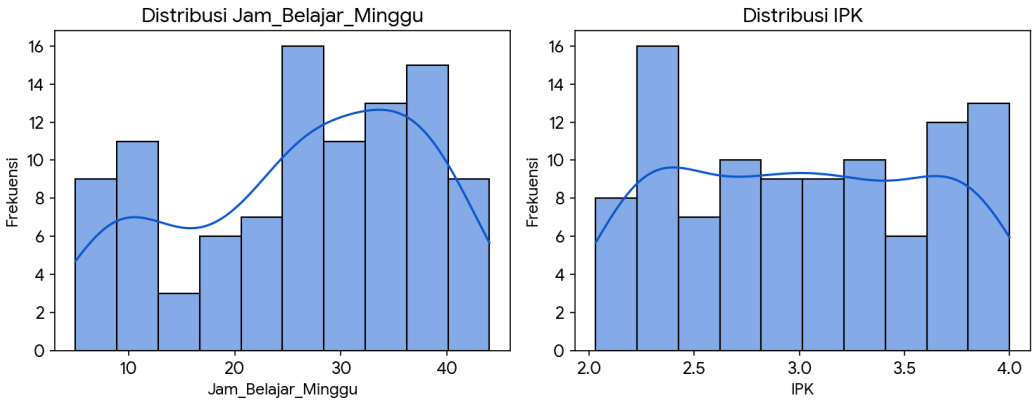
```
=== Atribut: Status_Lulus ===
```

Status_Lulus	Frekuensi	Persentase (%)
Lulus	75	75.0
Tidak Lulus	25	25.0

Interpretasi : Ketiga atribut kategorikal menunjukkan proporsi yang relatif seimbang antarkategori, tanpa kategori yang mendominasi secara signifikan. Ini merupakan ciri khas data yang dibangkitkan secara acak dengan peluang yang sama (np.random.choice), berbeda dari data lapangan yang umumnya memiliki ketimpangan kategori (class imbalance).

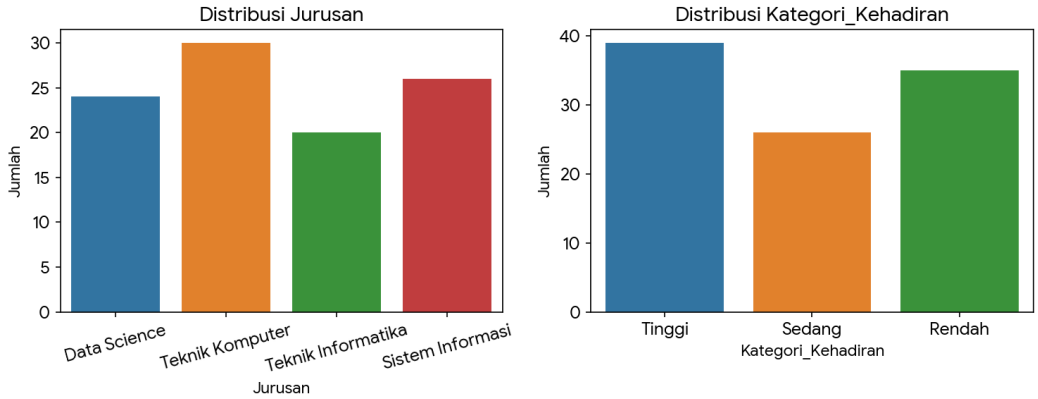
4. Visualisasi

a. Histogram



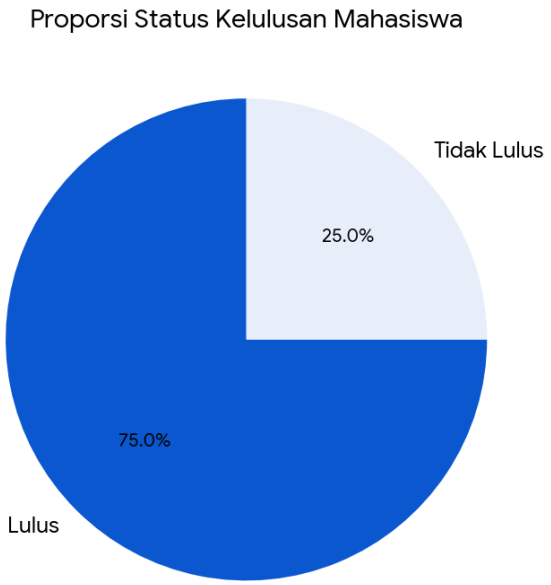
Interpretasi : Kedua histogram menunjukkan bentuk distribusi yang relatif datar di sepanjang rentang nilai - tinggi antarbin tidak jauh berbeda dan kurva KDE cenderung landai. Pola ini konsisten dengan metode pembangkitan data menggunakan distribusi seragam, berbeda dengan distribusi berbentuk lonceng (mendekati normal) yang biasa dijumpai pada data nilai ujian.

b. Count Plot



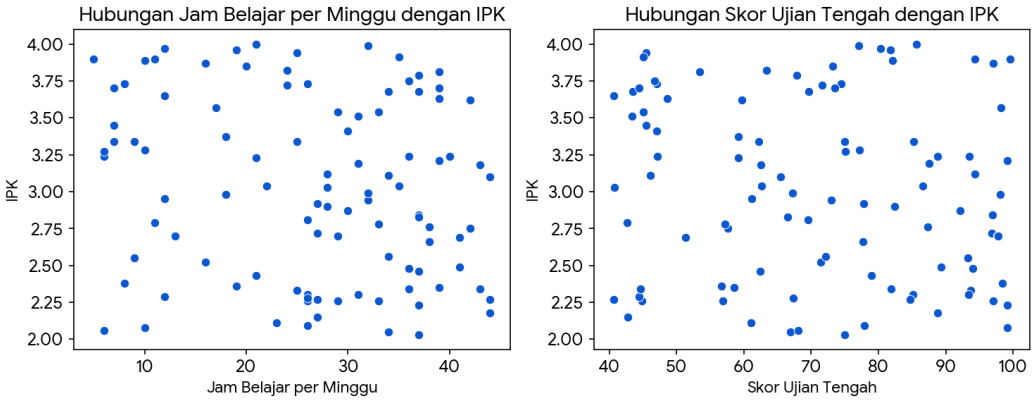
Interpretasi : Count plot mengonfirmasi secara visual hasil tabel frekuensi: tinggi batang antarkategori pada Jurusan dan Kategori_Kehadiran relatif setara, memudahkan perbandingan proporsi secara sekilas dibandingkan membaca tabel angka.

c. Pie Chart



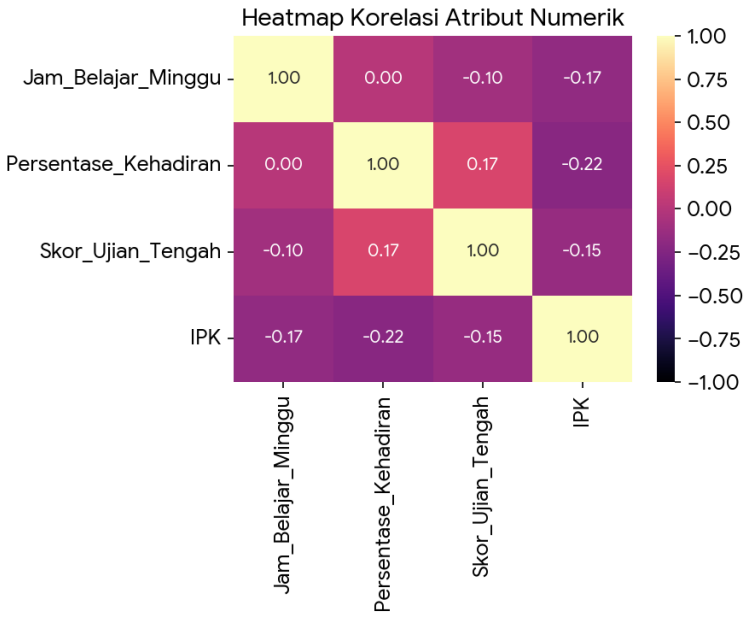
Interpretasi : Proporsi mahasiswa yang lulus ("Lulus" = 75%) dan yang tidak lulus ("Tidak Lulus" = 25%) berada pada proporsi persis sesuai probabilitas pembangkitan acak (75:25). Pie chart cukup efektif digunakan di sini karena atribut hanya memiliki dua kategori.

d. Scatter Plot



Interpretasi : Titik-titik pada kedua scatter plot tersebar merata memenuhi bidang grafik tanpa membentuk pola naik/turun tertentu, mengindikasikan tidak adanya hubungan linear yang jelas antara Jam_Belajar_Minggu maupun Skor_Ujian_Tengah terhadap IPK pada dataset ini.

e. Heatmap



Interpretasi : Seluruh nilai korelasi antarpasangan atribut numerik berada pada rentang sangat lemah (mendekati 0, baik positif maupun negatif), dengan nilai tertinggi hanya sekitar 0.17 (Skor_Ujian_Tengah dengan Persentase_Kehadiran). Tidak ditemukan pasangan atribut dengan korelasi kuat (>0.5), yang menegaskan bahwa atribut numerik pada dataset ini dibangkitkan secara independen satu sama lain.

5. Lima Temuan Utama

a. Dataset bersih tanpa missing value. Seluruh 100 observasi pada 8 atribut terisi penuh sehingga proses EDA dapat langsung dilakukan tanpa tahap pembersihan data.

b. Distribusi kategori yang seimbang. Atribut Jurusan, Kategori_Kehadiran, dan Status_Lulus masing-masing memiliki proporsi kategori yang relatif merata/sesuai probabilitas (tidak ada dominasi ekstrem tanpa alasan).

c. Distribusi atribut numerik cenderung seragam (uniform), bukan normal. Histogram Jam_Belajar_Minggu dan IPK menunjukkan sebaran yang relatif datar di seluruh rentang nilai.

d. Tidak terdapat korelasi kuat antarvariabel numerik. Baik melalui scatter plot maupun heatmap korelasi, seluruh pasangan atribut numerik menunjukkan korelasi yang sangat lemah.

e. Independensi variabel numerik terhadap IPK. Nilai IPK tidak menunjukkan ketergantungan atau tren khusus terhadap jam belajar maupun skor ujian tengah.

6. Kesimpulan

Dataset "Performa Mahasiswa" yang dibangun untuk latihan ini berhasil merepresentasikan seluruh jenis data yang dibahas pada Modul 1, yaitu identifier, data nominal, ordinal, biner, numerik diskrit, dan numerik kontinu, sehingga sesuai untuk tujuan pembelajaran EDA. Proses EDA menunjukkan bahwa dataset ini bersih (tanpa missing value), memiliki distribusi kategori yang seimbang, serta atribut numerik yang tersebar merata tanpa membentuk pola distribusi normal maupun hubungan korelasi yang kuat antarvariabel. Karakteristik ini merupakan konsekuensi langsung dari metode pembangkitan data menggunakan numpy.random dengan distribusi seragam dan tanpa ketergantungan matematis antaratribut.

7. Hal yang saya pelajari dan tantangan selama mengerjakan modul

Hal baru:

a. Fungsi DataFrame (df): Memahami dan mengoperasikan fungsi-fungsi dasar DataFrame pada Pandas untuk eksplorasi data tabel, yang merupakan pengalaman baru karena saya baru mulai mempelajari bahasa pemrograman Python.

b. Adaptasi Sintaks Python: Menyadari bahwa logika dan aturan penulisan (sintaks) Python ternyata memiliki banyak kemiripan dengan bahasa pemrograman yang sudah umum dipelajari seperti C++, sehingga cukup memudahkan proses adaptasi.

c. Visualisasi Grafik dan Peta: Mempelajari cara merender berbagai macam grafik visual (seperti histogram, count plot, scatter plot, dan heatmap) secara efisien menggunakan Matplotlib dan Seaborn.

Tantangan:

a. Memahami Fungsi Library: Membutuhkan waktu dan ketelitian untuk memahami fungsi spesifik dari masing-masing library (Pandas, NumPy, Matplotlib, Seaborn) yang harus diimpor dan digunakan secara terintegrasi dalam satu notebook.

b. Transisi Logika Pembuatan Data: Mengalami sedikit kesulitan saat mencoba mengimplementasikan numpy.random untuk menghasilkan data acak yang logis. Pada awalnya, saya hampir sepenuhnya menggunakan metode hardcode (mengetik nilai satu per satu secara manual) karena belum terbiasa, namun akhirnya tertantang untuk beralih menggunakan fungsi NumPy karena terbukti jauh lebih practical dan efisien untuk membuat ratusan baris data.

Referensi

Bruce, P., Bruce, A., & Gedeck, P. (2020). *Practical Statistics for Data Scientists: 50+ Essential Concepts Using R and Python* (2nd ed.). O'Reilly Media.

Grus, J. (2019). *Data Science from Scratch: First principles with Python* (2nd ed.). O'Reilly Media.

Modul 1 Daming Week #1: Pengantar Python dan EDA [Modul praktikum]. (2026). Sistem Cerdas, Ganjil 2026/2027.

Provost, F., & Fawcett, T. (2013). *Data Science for Business: What you need to know about data mining and data-analytic thinking*. O'Reilly Media.

Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.

VanderPlas, J. (2016). *Python Data Science Handbook: Essential tools for working with data*. O'Reilly Media.

Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J. (2016). *Data Mining: Practical machine learning tools and techniques* (4th ed.). Morgan Kaufmann.